Klasifikasi Sampah Berbasis Citra Menggunakan Jaringan Saraf Konvolusional (CNN): Studi Komparatif dengan Decision Tree, Random Forest, dan SVM untuk Mendukung Pengelolaan Sampah Berkelanjutan (SDG 12)

Nabila Carrissa Dewi - 234311021[1,]
Program Studi Teknologi rekayasa perangkat lunak
Fakultas teknik
Politeknik negeri madiun, Jl. Ring Road Barat, Kel. Winongo, Kec. Manguharjo
[1]nabilacarrissa@gmail.com

Abstract—Pengelolaan sampah yang tidak efisien merupakan permasalahan lingkungan serius yang berdampak pada ekosistem dan kesehatan masyarakat global, termasuk Indonesia. Penelitian ini menyajikan studi komparatif empat algoritma machine learning dan deep learning untuk klasifikasi sampah berbasis citra digital, yaitu Support Vector Machine (SVM), Random Forest (RF), Decision Tree (DT), dan Convolutional Neural Network (CNN). Dataset yang digunakan adalah Kaggle Garbage Classification yang terdiri atas 2.527 citra dalam enam kategori: cardboard, glass, metal, organic, paper, dan plastic. Tahap preprocessing meliputi Gaussian filter, resize citra, normalisasi piksel, dan augmentasi data. Ekstraksi fitur untuk SVM, DT, dan RF menggunakan Histogram of Oriented Gradients (HOG), sementara CNN mengekstraksi fitur secara otomatis melalui lapisan konvolusi. Hasil eksperimen menunjukkan bahwa SVM dengan kernel RBF mencapai akurasi tertinggi sebesar 66,67%, diikuti Random Forest 59,90%, Decision Tree 39,13%, dan CNN 22,22%. Temuan ini mengindikasikan bahwa pada dataset berukuran terbatas, metode machine learning klasik dengan fitur HOG yang terancang baik mampu mengungguli model deep learning. Penelitian ini berkontribusi terhadap implementasi Sustainable Development Goal (SDG) 12 melalui otomatisasi pemilahan sampah yang efisien dan akurat.

***Keywords*— klasifikasi sampah, CNN, SVM, Decision Tree, Random Forest, pengolahan citra digital, SDG 12.**

I. PENDAHULUAN

Pengelolaan sampah merupakan salah satu permasalahan global yang terus meningkat seiring dengan pertumbuhan populasi dan aktivitas manusia. Permasalahan ini menjadi perhatian penting dalam Sustainable Development Goals (SDGs), khususnya pada tujuan ke-12 yaitu Responsible Consumption and Production yang menekankan pada pengelolaan sumber daya secara efisien dan berkelanjutan. Salah satu upaya yang dapat dilakukan untuk mendukung tujuan tersebut adalah dengan meningkatkan sistem pemilahan sampah secara otomatis dan akurat.

Perkembangan teknologi kecerdasan buatan, khususnya dalam bidang pengolahan citra digital, membuka peluang untuk mengembangkan sistem klasifikasi sampah berbasis citra. Metode Convolutional Neural Network (CNN) merupakan salah satu pendekatan yang banyak digunakan karena kemampuannya dalam mengekstraksi fitur citra secara otomatis dan menghasilkan performa yang tinggi. Selain itu, beberapa metode machine learning seperti Support Vector Machine (SVM), Decision Tree, dan Random Forest juga sering digunakan sebagai pembanding dalam proses klasifikasi. Penelitian ini bertujuan untuk mengimplementasikan metode CNN dalam klasifikasi sampah berbasis citra serta melakukan studi komparatif dengan metode SVM, Decision Tree, dan Random Forest. Dataset yang digunakan berupa citra sampah dengan berbagai kategori seperti plastik, kertas, kaca, dan logam. Proses penelitian meliputi tahap preprocessing, ekstraksi fitur, pembagian data, pelatihan model, hingga evaluasi performa menggunakan metrik seperti akurasi dan confusion matrix.

Diharapkan hasil dari penelitian ini dapat memberikan kontribusi dalam pengembangan sistem klasifikasi sampah otomatis yang lebih efektif dan efisien, serta mendukung upaya pengelolaan sampah yang berkelanjutan sesuai dengan tujuan SDG 12.

II. TINJUAN PUSTAKA

Klasifikasi citra merupakan salah satu bidang penting dalam pengolahan citra digital yang bertujuan untuk mengelompokkan objek berdasarkan karakteristik tertentu. Dalam konteks pengelolaan sampah, klasifikasi citra digunakan untuk mengidentifikasi jenis sampah seperti plastik, kertas, kaca, dan logam secara otomatis. Berbagai metode telah dikembangkan untuk meningkatkan akurasi klasifikasi, baik menggunakan pendekatan machine learning maupun deep learning.

Salah satu metode yang banyak digunakan adalah Convolutional Neural Network (CNN). CNN merupakan bagian dari deep learning yang dirancang khusus untuk mengolah data berbentuk citra. Keunggulan CNN terletak pada kemampuannya dalam mengekstraksi fitur secara otomatis melalui lapisan konvolusi tanpa memerlukan ekstraksi fitur manual. Penelitian sebelumnya menunjukkan bahwa CNN mampu menghasilkan tingkat akurasi yang tinggi dalam berbagai tugas klasifikasi citra, termasuk klasifikasi

sampah.

Selain CNN, metode machine learning seperti Support Vector Machine (SVM) juga banyak digunakan dalam klasifikasi data. SVM bekerja dengan mencari hyperplane terbaik yang dapat memisahkan data ke dalam kelas yang berbeda. Metode ini dikenal memiliki performa yang baik pada data berdimensi tinggi, namun membutuhkan proses ekstraksi fitur yang tepat agar hasil klasifikasi optimal.

Metode lain yang sering digunakan adalah Decision Tree, yaitu algoritma klasifikasi berbasis struktur pohon yang mudah dipahami dan diinterpretasikan. Decision Tree bekerja dengan membagi data berdasarkan atribut tertentu hingga mencapai keputusan akhir. Meskipun sederhana, metode ini memiliki kelemahan berupa kecenderungan overfitting jika tidak dilakukan pengaturan parameter dengan baik.

Selanjutnya, Random Forest merupakan pengembangan dari Decision Tree yang menggunakan pendekatan ensemble. Random Forest membangun banyak pohon keputusan dan menggabungkan hasilnya untuk meningkatkan akurasi dan mengurangi overfitting. Metode ini terbukti lebih stabil dibandingkan Decision Tree tunggal dalam berbagai kasus klasifikasi.

Beberapa penelitian sebelumnya telah membandingkan performa metode deep learning dan machine learning dalam klasifikasi citra. Hasilnya menunjukkan bahwa metode CNN umumnya memiliki performa yang lebih unggul dibandingkan metode machine learning tradisional, terutama dalam menangani data citra yang kompleks. Oleh karena itu, penelitian ini menggunakan CNN sebagai metode utama dan membandingkannya dengan SVM, Decision Tree, dan Random Forest untuk mendapatkan model klasifikasi yang optimal dalam pengelolaan sampah berbasis citra.

III. METODOLOGI

Penelitian ini menggunakan pendekatan eksperimen dengan tujuan untuk membandingkan performa beberapa metode klasifikasi dalam mengidentifikasi jenis sampah berbasis citra. Metode utama yang digunakan adalah Convolutional Neural Network (CNN), serta metode pembanding yaitu Support Vector Machine (SVM), Decision Tree, dan Random Forest.

A. Dataset

Penelitian ini menggunakan dataset Garbage Classification yang tersedia secara publik di platform Kaggle. Dataset terdiri atas 4.133 citra digital yang terbagi ke dalam enam kategori kelas: cardboard (karton),Battery (baterai), glass (kaca), metal (logam), Clothes (pakaian), paper (kertas), dan plastic (plastik). Jumlah citra per kelas berkisar antara 385 hingga 775 gambar. Dataset ini bersifat representatif karena mencakup variasi kondisi pencahayaan, sudut pengambilan gambar, dan latar belakang yang beragam, sehingga mendekati kondisi nyata pemilahan sampah di lapangan.

B. Preprocessing

Tahap preprocessing bertujuan meningkatkan kualitas data masukan sebelum diproses oleh model. Tahap preprocessing diimplementasikan pada fungsi load_and_preprocess_dataset(). Pada tahap ini dilakukan beberapa proses, sebagai berikut.

Pertama, Membaca dataset gambar pada setiap folder kelas, Kedua, konversi warna dari format BGR (keluaran OpenCV) ke format RGB. Ketiga, penerapan Gaussian filter dengan kernel 3×3 piksel diterapkan untuk meredam noise pada citra. Keempat, citra di-resize ke dua ukuran: 224×224 piksel untuk CNN dan 64×64 piksel untuk ekstraksi fitur HOG. Kelima, normalisasi nilai piksel ke rentang [0, 1] dengan membagi nilai piksel dengan 255.

C. Feature Extraction

Dalam tahap ini ekstraksi fitur dilakukan dengan dua pendekatan yaitu CNN dan Mechine Learning, dimana Pada CNN Fitur ekstraksi dilakukan secara otomatis melalui layer konvolusi. Sedangkan Pada metode Machine Learning digunakan metode HOG atau Histogram of Oriented Gradients melalui fungsi ekstraksi_hog(). HOG bekerja dengan membagi citra menjadi sel-sel kecil dan menghitung distribusi arah gradien intensitas piksel pada setiap sel. Gradien dihitung sebagai perubahan intensitas piksel terhadap arah horizontal dan vertikal, kemudian diakumulasikan ke dalam histogram dengan 9 bin orientasi. Histogam antar sel dikelompokkan ke dalam blok berukuran 2×2 sel dan dinormalisasi untuk meningkatkan ketahanan terhadap perubahan pencahayaan.

Parameter HOG yang digunakan adalah: orientasi = 9 bin, ukuran sel = 8×8 piksel, dan ukuran blok = 2×2 sel. Pada citra berukuran 64×64 piksel, konfigurasi ini menghasilkan vektor fitur berdimensi 324 per citra. Sebelum digunakan untuk pelatihan model, vektor fitur HOG distandarisasi menggunakan StandardScaler (zero-mean, unit-variance) yang di-fit hanya pada data pelatihan untuk mencegah kebocoran informasi.

D. Split Data

Dataset ini dibagi menjadi tiga melalui fungsi bagi_data() dengan rasio 70% data pelatihan, 20% data validasi, dan 10% data pengujian. Selain itu, digunakan teknik stratified split untuk menjaga keseimbangan distribusi kelas. Pada data HOG juga dilakukan standarisasi menggunakan StandardScaler, yang di-fit pada data pelatihan, kemudian diterapkan ke data validasi dan pengujian menggunakan parameter yang sama.

E. Konfigurasi dan Pemodelan Model

Model Support Vector Machine (SVM) dikonfigurasi menggunakan kernel Radial Basis Function (RBF) dengan parameter regulasi C = 10 dan gamma = scale. Konfigurasi ini mengacu pada hasil penelitian sebelumnya yang menunjukkan performa optimal pada kombinasi parameter tersebut.

Model Random Forest dibangun dengan jumlah 150 pohon keputusan (n_estimators = 150) serta memanfaatkan seluruh inti prosesor (n_jobs = -1) untuk meningkatkan efisiensi komputasi.

Selanjutnya, model Decision Tree menggunakan kriteria Gini Index (CART) tanpa pembatasan kedalaman maksimum, sehingga memungkinkan pohon tumbuh secara penuh dalam mempelajari pola data. Adapun model Convolutional Neural Network (CNN) dibangun menggunakan empat blok konvolusi dengan jumlah filter berturut-turut 32, 64, 128, dan 256.

Setiap blok terdiri dari lapisan konvolusi, Batch Normalization, fungsi aktivasi ReLU, dan MaxPooling. Setelah proses ekstraksi fitur, digunakan Global Average Pooling yang diikuti oleh lapisan Dense dengan 256 neuron dan aktivasi ReLU, serta Dropout sebesar 0,5 untuk mengurangi overfitting. Lapisan output menggunakan fungsi aktivasi Softmax untuk klasifikasi multikelas (7 kelas). Model dikompilasi menggunakan optimizer Adam dengan laju pembelajaran sebesar 0,0001.

F. Evaluasi Model

Seluruh model dievaluasi menggunakan metrik akurasi, precision (weighted), recall (weighted), dan F1-score (weighted) pada data pengujian yang tidak terlibat dalam proses pelatihan maupun validasi. Penggunaan confusion matrix bertujuan untuk menganalisis pola kesalahan klasifikasi secara lebih rinci pada setiap kelas.

Evaluasi dilakukan dengan prosedur yang sama untuk seluruh model guna memastikan perbandingan kinerja yang objektif dan adil.

G. Output

Hasil penelitian divisualisasikan dalam beberapa bentuk, meliputi grafik akurasi dan loss selama proses pelatihan model CNN, confusion matrix untuk masing-masing model, serta grafik perbandingan performa antar model. Selain itu, sistem juga menghasilkan prediksi kelas terhadap citra uji yang ditampilkan bersama label hasil klasifikasi.

Output lain yang dihasilkan berupa model terlatih yang disimpan dalam format .h5 untuk CNN dan .pkl untuk model machine learning, sehingga dapat digunakan kembali pada tahap implementasi.

H. Pipleline

alur penelitian yang diterapkan dapat digambarkan sebagai berikut:

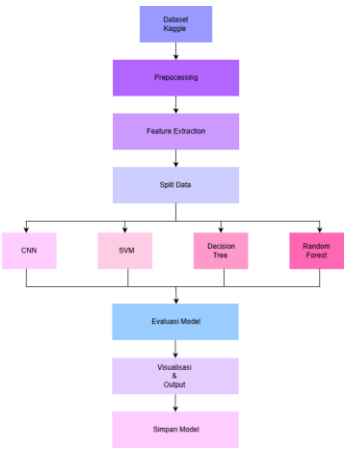

Gambar 3.1 Pipleline Flow

Pipeline ini dirancang secara sistematis untuk memastikan bahwa setiap tahapan penelitian berjalan secara terstruktur serta menghasilkan model klasifikasi yang optimal dan dapat dipertanggungjawabkan secara ilmiah.

IV. HASIL & PEMBAHASAN

A. Hasil Pelatihan CNN

ada tahap ini dilakukan proses pelatihan model Convolutional Neural Network (CNN) menggunakan data training dan validasi. Proses pelatihan bertujuan untuk mempelajari pola citra serta mengevaluasi kemampuan model dalam melakukan generalisasi terhadap data yang belum pernah dilihat. Kinerja model selama pelatihan diamati melalui dua metrik utama, yaitu akurasi dan nilai loss pada setiap epoch.

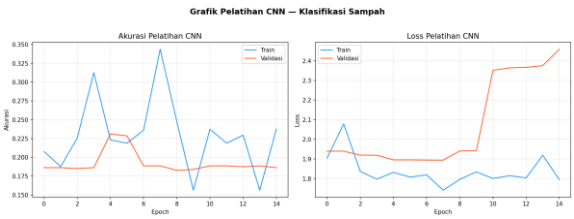

Gambar 4.1 grafik perkembangan akurasi dan loss selama proses pelatihan model CNN.

Berdasarkan Gambar 4.1, terlihat bahwa akurasi pada data training mengalami fluktuasi dengan nilai yang relatif rendah, yaitu berkisar antara 15% hingga 34%. Sementara itu, akurasi pada data validasi cenderung stagnan di kisaran 18% hingga 23% tanpa menunjukkan peningkatan yang signifikan seiring bertambahnya epoch. Hal ini menunjukkan bahwa model belum mampu mempelajari pola data secara optimal.

Selain itu, grafik loss menunjukkan bahwa nilai loss pada data training cenderung menurun secara perlahan, yang menandakan adanya proses pembelajaran. Namun, berbeda dengan loss training,

nilai loss pada data validasi justru mengalami peningkatan yang cukup signifikan setelah beberapa epoch. Kondisi ini mengindikasikan bahwa model mengalami overfitting, di mana model terlalu menyesuaikan diri terhadap data training tetapi gagal melakukan generalisasi pada data baru.

Secara keseluruhan, hasil pelatihan ini menunjukkan bahwa performa model CNN masih belum optimal. Rendahnya akurasi serta ketidakstabilan nilai loss menjadi indikasi bahwa model belum mampu menangkap representasi fitur yang efektif dari dataset yang digunakan. Faktor seperti keterbatasan jumlah data dan kompleksitas model yang tinggi diduga menjadi penyebab utama dari kondisi tersebut.

B. Analisis Penelitian

1) Perbandingan Performa Model

Hasil pelatihan CNN yang menunjukkan performa kurang optimal, baik dari segi akurasi maupun kestabilan loss, mengindikasikan adanya keterbatasan model dalam mempelajari pola data secara efektif. Hal ini menjadi dasar untuk melakukan evaluasi komparatif dengan model lain yang digunakan dalam penelitian ini.

Selanjutnya, dilakukan analisis perbandingan performa antara CNN dan model machine learning klasik, yaitu Support Vector Machine (SVM), Random Forest, dan Decision Tree, untuk menentukan model yang memiliki kinerja terbaik berdasarkan metrik evaluasi yang telah ditetapkan.

Model	Akurasi	Presisi	Recall	F1-Score
SVM RBF	66,67%	66,66%	66,67%	66,55%
Random Forest	59,90%	60,04%	59,90%	58,80%
Decision Tree	39.13%	39,90%	39,13%	39,39%
CNN	22,22%	8,03%	22,22%	11,77%

TABEL 4.1 PERBANDINGAN
PERFORMA MODEL PADA DATA TEST

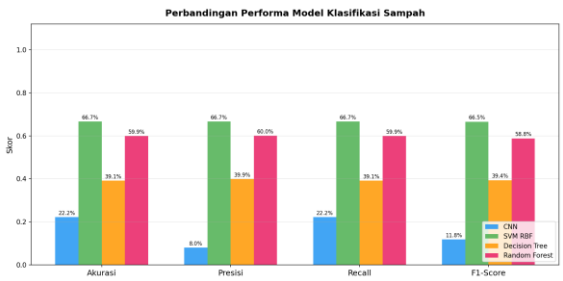

Gambar 4.2 Grafik Perbandingan Performa Model

Pada Tabel dan grafik diatas menunjukan bahwa model SVM RBF mencapai akurasi tertinggi sebesar 66,67% dengan presisi 66,67%, recall 66,67%, dan F1-score 66,55%. Konsistensi nilai antar metrik ini mengindikasikan bahwa SVM mampu melakukan klasifikasi secara relatif seimbang pada seluruh kelas tanpa kecenderungan bias yang signifikan. Keunggulan SVM pada penelitian ini menunjukkan efektivitas penggunaan fitur HOG yang bersifat diskriminatif, sehingga mempermudah model dalam memisahkan antar kelas meskipun jumlah data terbatas.

Model Random Forest menempati posisi kedua dengan akurasi sebesar 59,90%, dengan presisi 60,04%, recall 59,90%, dan F1-score 58,80%. Selisih performa sekitar 6–7% dibandingkan SVM menunjukkan bahwa meskipun pendekatan ensemble mampu meningkatkan stabilitas prediksi, performanya masih berada di bawah SVM. Hal ini disebabkan oleh karakteristik Random Forest yang bergantung pada kombinasi banyak pohon keputusan, sehingga sensitivitas terhadap fitur tidak seoptimal SVM dalam ruang fitur berdimensi tinggi.

Model Decision Tree mencatat akurasi sebesar 39,13%, dengan presisi 39,90%, recall 39,13%, dan F1-score 39,39%. Performa yang relatif rendah ini mengindikasikan keterbatasan kemampuan generalisasi model. Tanpa adanya pembatasan kedalaman (max depth), Decision Tree cenderung mengalami overfitting, yaitu terlalu menyesuaikan diri dengan data pelatihan sehingga tidak mampu mengenali pola baru pada data pengujian secara optimal.

Sementara itu, model CNN menghasilkan performa terendah dengan akurasi sebesar 22,22%, presisi 8,03%, recall 22,22%, dan F1-score 11,77%. Nilai presisi yang sangat rendah menunjukkan bahwa prediksi model cenderung tidak tepat dan tidak mampu membedakan kelas dengan baik. Kondisi ini mengindikasikan bahwa CNN gagal mempelajari representasi fitur yang efektif dari data citra yang tersedia. Rendahnya performa CNN dapat disebabkan oleh keterbatasan jumlah dataset serta tidak digunakannya pendekatan transfer learning, sehingga model dengan kompleksitas tinggi ini tidak mencapai konvergensi yang optimal.

2) Uji Coba

Untuk mensimulasikan penggunaan sistem dalam kondisi nyata, dilakukan uji coba model menggunakan citra sampah di luar dataset pelatihan dan pengujian. Pada tahap ini, sistem menerima input berupa gambar dari pengguna, kemudian memprosesnya menggunakan empat model klasifikasi, yaitu Support Vector Machine (SVM), Random Forest, Decision Tree, dan Convolutional Neural Network (CNN). Hasil prediksi dari masing-masing model ditampilkan secara terintegrasi dalam satu antarmuka visual.

Model	Prediksi	Jenis Sampah	Confidence
SVM RBF	Metal	Logam / Metal	64.7%
Random Forest	Metal	Logam / Metal	36.7%
Decision Tree	Metal	Logam / Metal	100.0%
CNN	Battery	Baterai	16.9%

Gambar 4.3 Uji Coba Prediksi

Berdasarkan Gambar 4.3, bagian kiri menampilkan citra asli yang diunggah oleh pengguna, disertai dengan hasil prediksi akhir yang diperoleh melalui mekanisme *majority voting*. Metode ini menentukan kelas berdasarkan hasil prediksi yang paling banyak muncul dari keempat model, sehingga meningkatkan keandalan keputusan sistem.

Pada bagian tengah dan kanan, ditampilkan hasil prediksi dari masing-masing model dalam bentuk kartu visual yang memuat nama model, kelas prediksi, serta nilai *confidence*. Selain itu, setiap model juga menampilkan distribusi probabilitas untuk seluruh kelas dalam bentuk diagram batang horizontal. Kelas dengan probabilitas tertinggi ditandai menggunakan warna yang lebih dominan untuk memudahkan interpretasi hasil klasifikasi.

Hasil uji coba menunjukkan bahwa model SVM dan Random Forest cenderung memberikan prediksi yang konsisten dengan tingkat *confidence* yang relatif stabil. Sebaliknya, Decision Tree dalam beberapa kasus menghasilkan nilai *confidence* yang lebih tinggi dibandingkan SVM, meskipun secara keseluruhan memiliki akurasi yang lebih rendah. Fenomena ini disebabkan oleh karakteristik Decision Tree yang cenderung menghasilkan probabilitas ekstrem pada node daun, sehingga bersifat *overconfident* terhadap prediksi yang dihasilkan.

Di sisi lain, SVM menghasilkan nilai probabilitas yang lebih moderat karena melalui proses kalibrasi probabilitas, sehingga lebih merepresentasikan tingkat ketidakpastian model secara realistis. Hal ini menjelaskan mengapa SVM tetap memiliki performa terbaik berdasarkan metrik evaluasi, meskipun tidak selalu menunjukkan nilai *confidence* tertinggi pada setiap prediksi individu.

Selain itu, model CNN menunjukkan distribusi probabilitas yang lebih menyebar pada beberapa kelas, yang mengindikasikan ketidakpastian dalam proses klasifikasi. Kondisi ini konsisten dengan hasil sebelumnya yang menunjukkan bahwa CNN memiliki keterbatasan dalam mempelajari representasi fitur secara optimal pada dataset berukuran terbatas.

Bagian bawah antarmuka menyajikan ringkasan hasil prediksi seluruh model dalam bentuk tabel, yang memuat informasi model, kelas prediksi, kategori sampah, serta nilai *confidence*. Penyajian ini memberikan gambaran komparatif yang memudahkan analisis perbedaan performa antar model terhadap citra yang sama.

Secara keseluruhan, hasil uji coba ini menunjukkan bahwa pendekatan multi-model dengan mekanisme *majority voting* mampu meningkatkan keandalan sistem dalam mengklasifikasikan sampah. Integrasi antara model machine learning klasik dan deep learning memberikan keseimbangan antara stabilitas dan fleksibilitas dalam menghadapi variasi data pada kondisi nyata.

3) Analisis Keunggulan SVM

Berdasarkan Tabel 4.2, model Support Vector Machine (SVM) dengan kernel RBF menunjukkan performa terbaik dibandingkan model lainnya, dengan nilai akurasi, precision, recall, dan F1-score yang relatif lebih tinggi dan konsisten. Hasil ini mengindikasikan bahwa SVM memiliki kemampuan klasifikasi yang lebih baik pada dataset yang digunakan dalam penelitian ini.

Keunggulan SVM tersebut menjadi menarik untuk dianalisis lebih lanjut, khususnya dalam konteks penggunaan dataset berukuran terbatas. Pada kondisi ini, SVM cenderung lebih efektif karena mampu bekerja dengan baik meskipun jumlah data tidak terlalu besar. Hal ini disebabkan oleh karakteristik SVM yang berfokus pada pembentukan hyperplane optimal dengan margin maksimum, sehingga mampu memisahkan kelas dengan lebih jelas tanpa memerlukan jumlah data yang besar.

Selain itu, penggunaan fitur hasil ekstraksi seperti Histogram of Oriented Gradients (HOG) turut memperkuat performa SVM, karena fitur tersebut telah merepresentasikan informasi penting dari citra, seperti bentuk dan tekstur objek. Dengan demikian, SVM tidak perlu mempelajari fitur dari awal seperti halnya CNN, melainkan langsung memanfaatkan fitur yang telah bersifat diskriminatif.

Dengan kombinasi antara efisiensi dalam penggunaan data dan representasi fitur yang kuat, SVM menjadi model yang paling unggul pada penelitian ini, khususnya dalam kondisi dataset yang terbatas.

4) Analisis Confusion Matrix

Untuk memperoleh pemahaman yang lebih mendalam mengenai kinerja masing-masing model dalam mengklasifikasikan data, tidak cukup hanya mengandalkan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score. Oleh karena itu, dilakukan analisis lebih lanjut menggunakan confusion matrix, yang memungkinkan identifikasi pola kesalahan prediksi secara spesifik pada setiap kelas.

Confusion matrix memberikan gambaran distribusi antara label aktual dan label prediksi, sehingga dapat diketahui kelas mana yang sering mengalami misklasifikasi serta hubungan kemiripan antar kelas. Dengan demikian, analisis ini menjadi penting untuk

mengevaluasi kemampuan generalisasi model secara lebih komprehensif.

Gambar 4.3 berikut menyajikan confusion matrix dari keempat model yang digunakan dalam penelitian ini, yaitu CNN, SVM (RBF), Decision Tree, dan Random Forest.

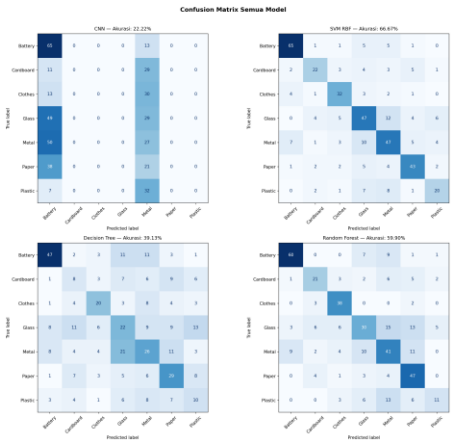

Gambar 4.4 Confusion Matrix

Analisis confusion matrix ini dilakukan untuk mengevaluasi pola prediksi masing-masing model secara lebih rinci pada setiap kelas. Berdasarkan Gambar 4.3, terlihat perbedaan yang signifikan dalam kemampuan klasifikasi antar model.

Pada model CNN, distribusi prediksi menunjukkan ketidakseimbangan yang sangat mencolok. Sebagian besar data dari berbagai kelas seperti *cardboard*, *clothes*, *glass*, *metal*, *paper*, dan *plastic* cenderung diprediksi sebagai kelas *metal*.

Hal ini mengindikasikan bahwa model mengalami bias prediksi yang kuat terhadap satu kelas dominan, sehingga kemampuan diskriminatif antar kelas menjadi sangat rendah. Fenomena ini konsisten dengan nilai akurasi CNN yang rendah 22,22%, yang menunjukkan kegagalan model dalam mempelajari representasi fitur yang memadai dari data.

Sebaliknya, model SVM dengan kernel RBF menunjukkan performa yang jauh lebih baik. Nilai diagonal pada confusion matrix relatif tinggi dan tersebar merata di hampir seluruh kelas, seperti *battery*, *glass*, *metal*, dan *paper*. Meskipun masih terdapat beberapa kesalahan klasifikasi, misalnya antara *glass* dan *metal* atau *paper* dan *cardboard*, pola kesalahan tersebut masih dalam batas wajar. Hal ini menunjukkan bahwa SVM memiliki kemampuan generalisasi yang baik serta mampu membedakan karakteristik antar kelas secara lebih konsisten dibanding model lainnya.

Model Random Forest juga menunjukkan pola yang cukup baik, meskipun tidak seoptimal SVM. Prediksi benar masih dominan pada diagonal, terutama untuk kelas seperti *battery*, *clothes*, dan *paper*. Namun, terdapat peningkatan kesalahan pada beberapa pasangan kelas yang memiliki kemiripan visual, seperti *glass* dengan *metal* serta *plastic* dengan *glass*. Hal ini menunjukkan bahwa meskipun metode ensemble mampu meningkatkan stabilitas prediksi, masih terdapat keterbatasan dalam membedakan fitur yang sangat mirip.

Sementara itu, model Decision Tree memperlihatkan distribusi kesalahan yang lebih menyebar. Walaupun beberapa kelas seperti *battery* dan *paper* masih dapat dikenali dengan cukup baik, kesalahan klasifikasi terjadi secara lebih acak di berbagai kelas. Pola ini mengindikasikan adanya overfitting, di mana model terlalu menyesuaikan diri dengan data pelatihan namun gagal melakukan generalisasi pada data pengujian.

Secara keseluruhan, analisis confusion matrix ini memperkuat hasil evaluasi kuantitatif sebelumnya, di mana SVM menjadi model dengan performa terbaik, diikuti oleh Random Forest, Decision Tree, dan CNN. Perbedaan ini terutama terlihat dari kemampuan masing-masing model dalam mempertahankan konsistensi prediksi benar pada setiap kelas serta meminimalkan kesalahan klasifikasi antar kelas yang memiliki kemiripan visual.

5) Analisis Kelebihan dan Kekurangn Model

Berdasarkan hasil evaluasi performa dan analisis confusion matrix, masing-masing model menunjukkan karakteristik kelebihan dan keterbatasan yang berbeda dalam menangani tugas klasifikasi citra sampah.

Model Support Vector Machine (SVM) dengan kernel RBF menunjukkan performa terbaik di antara seluruh model yang diuji. Kelebihan utama SVM terletak pada kemampuannya dalam memanfaatkan fitur HOG yang telah direkayasa secara efektif, sehingga mampu membentuk batas keputusan (decision boundary) yang optimal pada ruang fitur berdimensi tinggi. Selain itu, SVM memiliki kemampuan generalisasi yang baik pada dataset berukuran terbatas, sebagaimana ditunjukkan oleh distribusi prediksi yang relatif seimbang pada confusion matrix. Namun demikian, SVM memiliki keterbatasan dalam hal interpretabilitas model serta kurang fleksibel ketika dihadapkan pada dataset berskala sangat besar, karena kompleksitas komputasinya meningkat secara signifikan.

Model Random Forest menempati posisi kedua dengan performa yang cukup stabil. Kelebihan utama Random Forest adalah kemampuannya dalam mengurangi variansi melalui mekanisme ensemble dari banyak pohon keputusan, sehingga lebih tahan terhadap overfitting dibanding Decision Tree tunggal. Selain itu, model ini relatif mudah digunakan tanpa memerlukan proses normalisasi fitur yang kompleks. Namun, kekurangan Random Forest terletak pada ukuran model yang cenderung besar serta interpretabilitas yang lebih rendah, karena keputusan akhir merupakan hasil agregasi dari banyak pohon.

Model Decision Tree memiliki keunggulan dari sisi interpretabilitas, di mana proses pengambilan keputusan dapat divisualisasikan dalam bentuk struktur pohon yang mudah dipahami. Hal ini menjadikan Decision Tree sebagai model yang transparan dan intuitif. Akan tetapi, model ini menunjukkan kelemahan yang cukup

signifikan berupa kecenderungan overfitting, terutama ketika tidak diberikan batasan pada kedalaman pohon. Hal ini terlihat dari distribusi kesalahan yang lebih menyebar pada confusion matrix serta performa yang lebih rendah dibandingkan model lainnya.

Sementara itu, model Convolutional Neural Network (CNN) menunjukkan performa paling rendah dalam penelitian ini. Secara teoritis, CNN memiliki keunggulan dalam melakukan ekstraksi fitur secara otomatis langsung dari data citra mentah tanpa memerlukan rekayasa fitur manual. Namun, keunggulan tersebut tidak dapat dimaksimalkan pada penelitian ini karena keterbatasan jumlah data pelatihan. CNN memerlukan dataset yang besar untuk dapat mempelajari representasi fitur yang optimal. Selain itu, kompleksitas model yang tinggi menyebabkan kebutuhan komputasi yang lebih besar serta waktu pelatihan yang lebih lama. Hal ini tercermin dari hasil confusion matrix yang menunjukkan ketidakseimbangan prediksi dan rendahnya kemampuan model dalam membedakan antar kelas.

Secara keseluruhan, hasil analisis ini menunjukkan bahwa pemilihan model sangat bergantung pada karakteristik dataset dan pendekatan fitur yang digunakan. Pada kondisi dataset terbatas dengan fitur yang telah direkayasa dengan baik, model machine learning klasik seperti SVM dan Random Forest dapat memberikan performa yang lebih optimal dibandingkan model deep learning seperti CNN.

C. Diskusi dan Implementasi SDG 12

Hasil penelitian ini menunjukkan bahwa model Support Vector Machine (SVM) dengan kernel RBF memberikan performa terbaik dibandingkan model lainnya dalam klasifikasi citra sampah pada dataset yang digunakan. Temuan ini memberikan implikasi penting, baik dari sisi teknis pengembangan model maupun dari perspektif implementasi dalam mendukung Sustainable Development Goals (SDG) 12: Responsible Consumption and Production.

Gambar 4.4 Logo SDG 12

Dari perspektif teknis, hasil penelitian menegaskan bahwa penggunaan metode machine learning klasik dengan dukungan rekayasa fitur yang tepat, seperti Histogram of Oriented Gradients (HOG), masih sangat relevan dan bahkan unggul dalam kondisi dataset terbatas. Hal ini menjadi insight penting bahwa pemilihan metode tidak hanya bergantung pada kompleksitas model, tetapi juga pada kesesuaian antara karakteristik data dan pendekatan yang digunakan. Dengan demikian, pendekatan yang lebih sederhana namun tepat dapat menghasilkan performa yang optimal tanpa memerlukan sumber daya komputasi yang besar.

Dari sisi implementasi, model SVM yang relatif ringan dan efisien membuka peluang besar untuk diterapkan pada sistem klasifikasi sampah otomatis berbasis perangkat *edge computing*, seperti smart trash bin atau sistem pemilahan sampah berbasis kamera. Kemampuan model untuk melakukan inferensi secara cepat dengan kebutuhan komputasi yang rendah memungkinkan implementasi pada perangkat dengan keterbatasan sumber daya, seperti Raspberry Pi atau sistem embedded lainnya. Hal ini menjadi keunggulan signifikan dibandingkan model CNN yang umumnya memerlukan GPU untuk mencapai performa optimal.

Dalam konteks SDG 12, sistem klasifikasi sampah otomatis yang akurat dapat berkontribusi secara langsung terhadap peningkatan efisiensi proses pemilahan sampah di sumbernya. Pemilahan yang tepat antara kategori seperti plastik, kertas, logam, dan kaca merupakan langkah awal yang krusial dalam meningkatkan tingkat daur ulang dan mengurangi jumlah limbah yang berakhir di tempat pembuangan akhir. Dengan adanya sistem berbasis kecerdasan buatan, proses ini dapat dilakukan secara lebih konsisten dan minim kesalahan dibandingkan metode manual.

Lebih lanjut, penerapan teknologi ini juga berpotensi meningkatkan kesadaran masyarakat terhadap pentingnya pengelolaan sampah yang bertanggung jawab. Integrasi sistem klasifikasi otomatis dalam lingkungan publik, seperti sekolah, perkantoran, atau ruang publik, dapat menjadi sarana edukasi yang interaktif sekaligus praktis dalam mendukung perubahan perilaku masyarakat menuju pola konsumsi dan produksi yang lebih berkelanjutan.

Namun demikian, terdapat beberapa keterbatasan yang perlu diperhatikan. Model yang dikembangkan dalam penelitian ini masih bergantung pada dataset dengan skala terbatas, sehingga generalisasi pada kondisi dunia nyata yang lebih kompleks perlu diuji lebih lanjut. Selain itu, variasi kondisi pencahayaan, latar belakang, dan kualitas citra dalam implementasi nyata dapat memengaruhi performa model. Oleh karena itu, pengembangan lanjutan seperti penambahan data, penggunaan teknik augmentasi yang lebih variatif, atau penerapan transfer learning pada CNN menjadi arah penelitian yang potensial.

Secara keseluruhan, penelitian ini menunjukkan bahwa pendekatan yang efisien dan tepat guna dalam klasifikasi sampah tidak hanya memberikan kontribusi pada pengembangan teknologi, tetapi juga memiliki dampak nyata dalam mendukung pencapaian tujuan pembangunan berkelanjutan, khususnya dalam pengelolaan sumber daya dan limbah yang lebih bertanggung jawab.

V. KESIMPULAN

Penelitian ini bertujuan untuk membandingkan kinerja beberapa metode klasifikasi citra, yaitu Convolutional Neural Network (CNN), Support Vector Machine (SVM) dengan kernel RBF, Decision Tree, dan Random Forest dalam mengklasifikasikan citra sampah. Berdasarkan hasil eksperimen yang telah dilakukan, dapat disimpulkan bahwa model SVM RBF menunjukkan performa terbaik dengan akurasi sebesar 66,67%, diikuti oleh Random Forest (59,90%), Decision Tree (39,13%), dan CNN (22,22%).

Hasil ini menunjukkan bahwa pada kondisi dataset terbatas, pendekatan machine learning klasik yang didukung oleh rekayasa fitur seperti Histogram of Oriented Gradients (HOG) mampu memberikan performa yang lebih optimal dibandingkan model deep learning yang dilatih dari awal (from scratch). Analisis confusion matrix memperkuat temuan ini, di mana SVM mampu mengklasifikasikan sebagian besar kelas dengan distribusi prediksi yang lebih seimbang, sementara CNN menunjukkan bias prediksi yang tinggi terhadap kelas tertentu.

Selain itu, hasil penelitian juga mengindikasikan bahwa kompleksitas model tidak selalu berbanding lurus dengan performa. CNN yang secara teoritis unggul dalam pengolahan citra tidak mampu mencapai hasil optimal akibat keterbatasan jumlah data pelatihan. Sebaliknya, SVM dengan konfigurasi yang relatif sederhana justru mampu melakukan generalisasi dengan lebih baik.

Dari sisi implementasi, model SVM memiliki keunggulan dalam efisiensi komputasi dan kecepatan inferensi, sehingga lebih sesuai untuk diterapkan pada sistem klasifikasi sampah berbasis perangkat dengan sumber daya terbatas. Temuan ini memberikan kontribusi praktis dalam pengembangan sistem pemilahan sampah otomatis yang mendukung peningkatan efisiensi pengelolaan limbah.

Secara keseluruhan, penelitian ini menegaskan bahwa pemilihan metode klasifikasi harus mempertimbangkan karakteristik dataset, ketersediaan data, serta kebutuhan implementasi. Dengan pendekatan yang tepat, sistem klasifikasi berbasis kecerdasan buatan dapat berkontribusi dalam mendukung pengelolaan sampah yang lebih efektif dan berkelanjutan.

VI. LAMPIRAN

A. Konfigurasi Lingkungan dan Library

Penelitian ini diimplementasikan menggunakan bahasa pemrograman Python 3.10 dengan library utama meliputi TensorFlow dan Keras untuk pengembangan model Convolutional Neural Network (CNN), serta scikit-learn untuk implementasi algoritma Support Vector Machine (SVM), Decision Tree (DT), dan Random Forest (RF). Selain itu, digunakan OpenCV untuk pemrosesan citra dan scikit-image untuk ekstraksi fitur Histogram of Oriented Gradients (HOG).

Eksperimen dijalankan pada platform Google Colaboratory dengan dukungan akselerasi GPU untuk mempercepat proses pelatihan model CNN.

B. Parameter dan Konfigurasi Model

Berikut merupakan parameter utama yang digunakan dalam penelitian:

- **SVM (RBF Kernel)**
  Parameter: C = 10, gamma = scale
- **Random Forest**
  Jumlah pohon (n_estimators) = 150
- **Decision Tree**
  Kriteria: Gini Index, tanpa pembatasan kedalaman maksimum
- **CNN**
  Arsitektur terdiri dari empat blok konvolusi (32, 64, 128, 256 filter), Batch Normalization, ReLU, MaxPooling, Global Average Pooling, Dense (256 neuron), Dropout (0,5), dan output Softmax.

C. Proses Preprocessing dan Ekstraksi Fitur

Tahapan preprocessing citra meliputi:

1. Resize citra menjadi 224×224 piksel untuk CNN dan 64×64 piksel untuk HOG
2. Normalisasi piksel ke rentang 0–1 (khusus CNN)
3. Konversi ke grayscale untuk ekstraksi fitur HOG
4. Ekstraksi fitur HOG dengan parameter orientasi 9, pixels per cell (8×8), dan cells per block (2×2)

D. Dataset

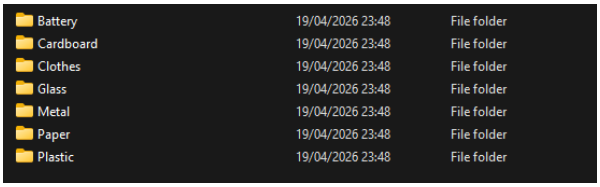

Battery	19/04/2026 23:48	File folder
Cardboard	19/04/2026 23:48	File folder
Clothes	19/04/2026 23:48	File folder
Glass	19/04/2026 23:48	File folder
Metal	19/04/2026 23:48	File folder
Paper	19/04/2026 23:48	File folder
Plastic	19/04/2026 23:48	File folder

E. Cuplikan Kode

```python
def load_and_preprocess_dataset(dataset_dir, img_size, img_size_hog):
    """
    Memuat seluruh dataset gambar, melakukan preprocessing, dan
    mengembalikan array gambar beserta label-nya.

    Args:
        dataset_dir  : path root folder dataset
        img_size     : tuple (h, w) untuk CNN
        img_size_hog : tuple (h, w) untuk HOG / ML klasik

    Returns:
        images_cnn  : array (N, H, W, 3) ternormalisasi untuk CNN
        images_hog  : array (N, H, W, 3) untuk ekstraksi HOG
        labels      : array string nama kelas
        label_enc   : LabelEncoder yang sudah di-fit
    """
    images_cnn  = []
    images_hog  = []
    labels      = []
    dataset_dir = Path(dataset_dir)

    print("\n[LOAD] Memuat dataset ...")
    for kelas in KELAS:
        kelas_dir = dataset_dir / kelas
        if not kelas_dir.exists():
            print(f"  [PERINGATAN] Folder tidak ditemukan: {kelas_dir}")
            continue
```

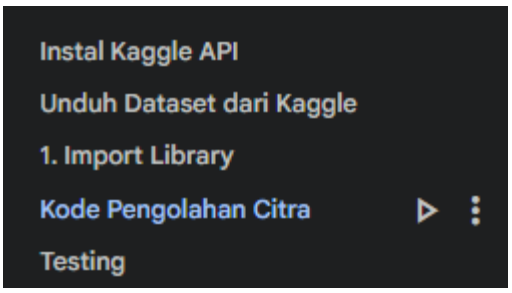

VII. UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada dosen pembimbing atas arahan, masukan konstruktif, dan dukungan yang diberikan selama proses penelitian ini. Penulis juga mengapresiasi dukungan dari institusi yang telah memfasilitasi pelaksanaan penelitian.

Selain itu, penulis menyampaikan terima kasih kepada penyedia dataset publik yang digunakan dalam penelitian ini, yang telah memberikan kontribusi signifikan terhadap proses eksperimen dan analisis.

REFERENCES

[1] W.-K. Chen, *Linear Networks and Systems* (Book style). Belmont, CA: Wadsworth, 1993, pp. 123–135.
[2] B. Smith, "An approach to graphs of linear forms (Unpublished work style)," unpublished.
[3] J. Wang, "Fundamentals of erbium-doped fiber amplifiers arrays (Periodical style—Submitted for publication)," *IEEE J. Quantum Electron.*, submitted for publication.
[4] M. HAQQI, L. ROCHMAH, A. D. SAFITRI, R. A. PRATAMA, AND TARWOTO, "IMPLEMENTATION OF MACHINE LEARNING TO IDENTIFY TYPES OF WASTE USING CNN ALGORITHM," J. FASILKOM, VOL. 14, NO. 3, PP. 761–765, DEC. 2024, DOI: 10.37859/JF.V14I3.8116

PERNYATAAN

Dengan ini saya menyatakan bahwa makalah yang saya tulis ini adalah tulisan saya sendiri, bukan saduran, atau terjemahan dari makalah orang lain, dan bukan plagiasi.

Madiun, 20 April 2026

Nabila Carrissa Dewi (234311021)